DIC5 課堂實作：電影網站爬蟲 (Web Scraping Project Report)

1. 專案簡介與目標 (Project Overview)

本專案為 DIC5 課堂之爬蟲實作練習。主要目標為撰寫一個 Python 爬蟲程式，從演示網站 `https://ssr1.scrape.center` 中抓取電影公開資訊。
專案規格要求涵蓋 10 個分頁（共 100 筆資料），並針對每部電影精準萃取以下關鍵資訊欄位：電影名稱（`title`）、詳細頁連結（`detail_url`）、海報圖片網址（`image`）、類型（`categories`）、地區（`region`）、片長（`duration`）、上映日期（`release_date`）與評分（`score`）。最終將爬取結果統一清理、整理並輸出為 CSV 與 JSON 檔案格式。

2. 使用技術與工具 (Technologies & Tools)

- **程式語言**：Python 3
- **網路請求**：`requests` 套件（負責發送 HTTP 請求並處理例外）
- **網頁解析**：`BeautifulSoup4` （負責解析 HTML 結構並利用 CSS 選擇器萃取目標欄位）
- **資料儲存**：`csv` 及 `json` 標準套件
- **版本控制**：Git 與 GitHub

3. 實作過程與技術亮點 (Implementation Details)

3.1 網頁結構分析與定位

開發階段首先分析網站的 HTML 結構，透過瀏覽器的開發者工具確認各個目標欄位的對應標籤與 CSS Class：

- **電影區塊**：定位於 `.el-card.item` ，以此為基準迭代單頁上的每一部電影。
- **資訊擷取欄位**：
  - 標題：`h2.m-b-sm`
  - 類別：`.categories span` （抓出所有類別後利用 `,` 字元串接）
  - 上映時間：第二個 `.m-v-sm.info` （部分電影無上映時間，實作中已涵蓋防呆邏輯避免程式崩潰）

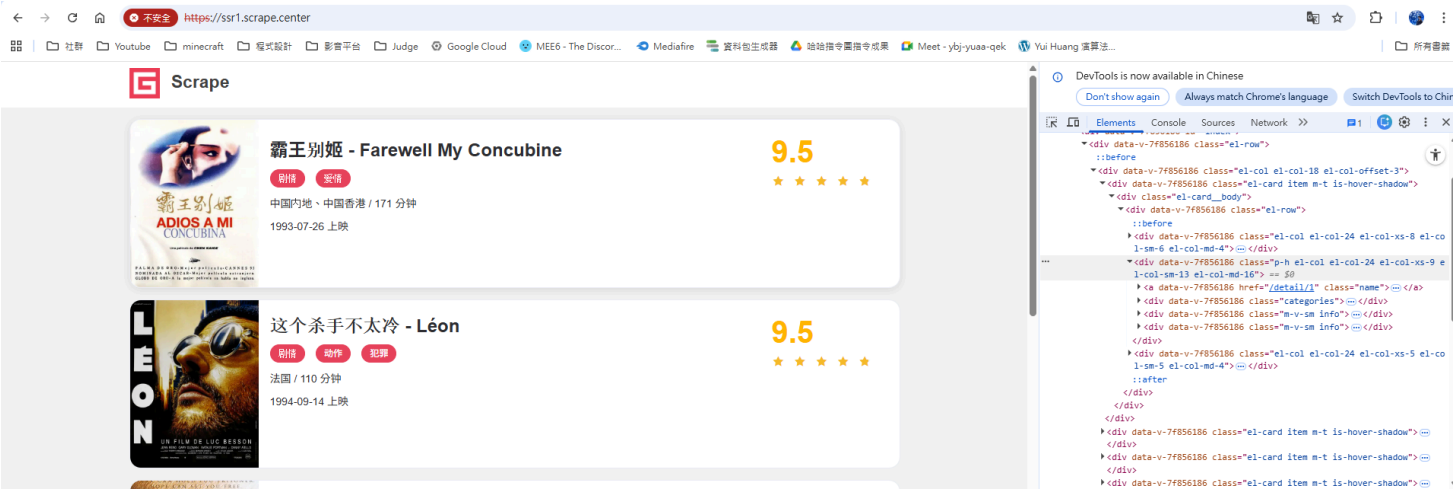

3.2 網路請求防呆與請求間隔控制

為了提升爬蟲的強健性與友善度，針對 `requests.get` 引入了完整的 `try-except` 處理網路連線異常，並加上了 SSL 安全憑證略過設定 (`verify=False`)。同時，在不同分頁爬取之間引入 `time.sleep(1)` 延遲，以避免快速發送高頻請求對目標伺服器造成負擔。

3.3 資料清理與導出

將各分頁萃取的結果裝入字典 (Dictionary) 後，最終將陣列整併並透過標準的檔案串流，依序匯出符合題目要求的 UTF-8 (帶 BOM) 的 `movies.csv` 。作為進階挑戰，專案中也同樣封裝了 `movies.json` 的產生，方便於後續在不同前端介面及資料庫系統中使用。

4. 專案成果展示 (Results & Deliverables)

該爬蟲程式已成功自動化抓取 10 頁，獲得 100 筆完整的電影資料。

4.1 核心程式運作紀錄

以下為程式運行於本地終端機時的紀錄，程式可精準追蹤目前的爬取頁數並成功輸出檔案。

```
[Running] python -u "c:\Users\user\Desktop\HW2\scraper.py"
Scraping: https://ssr1.scrape.center/page/1
Scraping: https://ssr1.scrape.center/page/2
Scraping: https://ssr1.scrape.center/page/3
Scraping: https://ssr1.scrape.center/page/4
Scraping: https://ssr1.scrape.center/page/5
Scraping: https://ssr1.scrape.center/page/6
Scraping: https://ssr1.scrape.center/page/7
Scraping: https://ssr1.scrape.center/page/8
Scraping: https://ssr1.scrape.center/page/9
Scraping: https://ssr1.scrape.center/page/10
Successfully saved data for 100 movies to movies.csv
Bonus: Successfully saved data to movies.json

[Done] exited with code=0 in 12.927 seconds
```

4.2 CSV 產出結果

輸出的 `movies.csv` 格式排列正確且中文無亂碼。

title	detail_url	image	categories	region	duration	r
霸王别姬 - Farewell My Concubine	https://ssr1.scrape.center/detail/1	https://p0.meituan.net/movie/ce4da3e03e655b5b88ed31b5cd7896cf62472.jpg@464w_644h_1e_1c	剧情,爱情	中国内地、中国香港	171 分钟	19
这个杀手不太冷 - Léon	https://ssr1.scrape.center/detail/2	https://p1.meituan.net/movie/6bea9af4524dfbd0b668eaa7e187c3df767253.jpg@464w_644h_1e_1c	剧情,动作,犯罪	法国	110 分钟	19
肖申克的救赎 - The Shawshank Redemption	https://ssr1.scrape.center/detail/3	https://p0.meituan.net/movie/283292171619cdfd5b240c8fd093f1eb255670.jpg@464w_644h_1e_1c	剧情,犯罪	美国	142 分钟	19
泰坦尼克号 - Titanic	https://ssr1.scrape.center/detail/4	https://p1.meituan.net/movie/b607fba7513e7f15eab170aac1e1400d878112.jpg@464w_644h_1e_1c	剧情,爱情,灾难	美国	194 分钟	19
罗马假日 - Roman Holiday	https://ssr1.scrape.center/detail/5	https://p0.meituan.net/movie/289f98ceaa8a0ae737d1dc01cd05ab052213631.jpg@464w_644h_1e_1c	剧情,喜剧,爱情	美国	118 分钟	19
唐伯虎点秋香 - Flirting Scholar	https://ssr1.scrape.center/detail/6	https://p0.meituan.net/movie/da64660f82b98cdc1b8a3804e69609e041108.jpg@464w_644h_1e_1c	喜剧,爱情,古装	中国香港	102 分钟	19
乱世佳人 - Gone with the Wind	https://ssr1.scrape.center/detail/7	https://p0.meituan.net/movie/223c3e186db3ab4ea3bb14508c709400427933.jpg@464w_644h_1e_1c	剧情,爱情,历史,战争	美国	238 分钟	19
喜剧之王 - The King of Comedy	https://ssr1.scrape.center/detail/8	https://p0.meituan.net/movie/1f0d671f6a37f9d7b015e4682b8b113e174332.jpg@464w_644h_1e_1c	剧情,喜剧,爱情	中国香港	85 分钟	19
楚门的世界 - The Truman Show	https://ssr1.scrape.center/detail/9	https://p0.meituan.net/movie/8959888ee0c399b0fe53a714bc8a5a17460048.jpg@464w_644h_1e_1c	剧情,科幻	美国	103 分钟	

4.3 JSON 產出結果（加分項完成）

輸出的 `movies.json` 以 4 空格縮排並允許非 ASCII 顯示，結構清晰。

```
[
    {
        "title": "霸王别姬 - Farewell My Concubine",
        "detail_url": "https://ssr1.scrape.center/detail/1",
        "image": "https://p0.meituan.net/movie/ce4da3e03e655b5b88ed31b5cd7896cf62472.jpg@
        "categories": "剧情,爱情",
        "region": "中国内地、中国香港",
        "duration": "171 分钟",
        "release_date": "1993-07-26 上映",
        "score": "9.5"
    },
    {
        "title": "这个杀手不太冷 - Léon",
        "detail_url": "https://ssr1.scrape.center/detail/2",
        "image": "https://p1.meituan.net/movie/6bea9af4524dfbd0b668eaa7e187c3df767253.jpg
        "categories": "剧情,动作,犯罪",
        "region": "法国",
        "duration": "110 分钟",
        "release_date": "1994-09-14 上映",
        "score": "9.5"
    },
```


5. 總結 (Conclusion)

本次實作中，成功組合並善用了 Python 強大的 `requests` 與 `BeautifulSoup` 開發生態，解決了靜態表單解析、多層次 CSS Selector 定位以及邊界狀況（如部分電影缺漏資訊）等開發爬蟲時常見的基礎挑戰，並最終達成了自動化整理與資料格式化的實務演練。